

FEEL Phase 1 — Method and Results

FEEL project

2026-06-04

1 개요

FEEL Phase 1 은 세 종류의 brain foundation model (BFM, Brain-JEPA, NeuroSTORM, SwiFT) 의 frozen encoder 에서 추출한 embedding 이 Horikawa 의 naturalistic video fMRI 데이터 위에서 emotion 관련 task 를 얼마나 잘 capture 하는지 측정하는 것이 목적이다. 모든 BFM 은 weight 가 고정 (frozen) 된 상태로 inference 만 수행하며, 그 위에 linear probe (sklearn 의 Ridge / Logistic regression) 와 MLP probe (SwiFT 의 downstream MLP head 를 vendored) 를 학습시켜 각 task 의 점수를 측정한다.

비교 reference 로 (a) feature 무관 chance baseline, (b) ROI mean BOLD (Schaefer 400 cortical + Tian S3 50 subcortical) 의 Tier 1 floor, (c) video stimulus 의 vision encoder (CLIP, DINOv2, VideoMAE, V-JEPA2) 와 caption embedding (Qwen-VL) 의 Tier 3 baseline 을 함께 측정했다.

본 문서는 Phase 1 의 방법 (method) 과 측정된 결과 (result) 만을 정리한다. Audit 단계에서 발견된 정합성 caveat 은 마지막 section 에 짧게 명기한다.

2 Methods

2.1 Data

- Stimulus pool. Horikawa naturalistic video fMRI 의 canonical 2185 자극. Resting fMRI 와 11 개 반복 자극 (stimulus_2186–stimulus_2196) 은 제외.
- Subjects. 5 명 (sub-01 – sub-05).
- Per-stim 시계열 길이 (T). 자극마다 서로 다른 비디오 길이. 중앙값 5, 평균 6.08, 최대 47, 99 percentile 19. 전체 자극의 71.6% (1565 / 2185) 가 $T = 5$.
- Ratings. Cowen 의 34 emotion category score (자극당 0–1 사이의 float 점수 34 개) 와 14 dimensional affective rating (arousal, dominance, valence, approach, attention, certainty, commitment, control, effort, fairness, identity, obstruction, safety, upswing), 그리고 valence (1–9) 와 arousal (2–8.67) continuous score.
- Quartile labels. 2185 자극의 valence score 를 4 quartile 로 나눠 $v_quartile \in \{0, 1, 2, 3\}$ 라벨, arousal 도 동일하게 $a_quartile$ 라벨 부여. quartile 0 이 lowest, quartile 3 이 highest.

2.2 Split

5-fold cross-validation 의 fold 정의는 `data/horikawa_5fold.csv.v_quartile × a_quartile` 의 joint label (16 cell) 에 대해 `sklearn.StratifiedKFold(n_splits=5, shuffle=True, random_state=0)` 적용. 같은 자극은 모든 5 subject 에서 같은 fold 에 들어가도록 한다 (stim-level leakage 없음).

각 fold $k \in \{1, 2, 3, 4, 5\}$ 에 대해

- test = fold k
- val = fold $(k \bmod 5) + 1$
- train = 나머지 세 fold

즉 자극 단위로 train 60% / val 20% / test 20% 가 fold 별로 회전.

2.3 Brain foundation model embedding 추출

세 BFM 모두 동일한 protocol 을 따른다.

- Frozen encoder. 사전학습된 (또는 random init 된 scratch baseline 의) 모델 weight 를 그대로 `model.eval()` 로 inference 모드 전환 후 `torch.no_grad()` 안에서 forward. 학습 가능한 parameter 는 없다.
- Temporal padding. 모든 BFM 에 zero padding 적용. 자극의 실제 시계열 길이가 모델의 input 길이 보다 짧으면 부족한 frame 을 zero 로 채움.
- 모델별 input 길이.
 - Brain-JEPA. 16 TR (ViT-Base, patch_size=16). $T \geq 16$ 자극은 중앙 16 TR 만 사용 (center crop), $T < 16$ 은 zero padding.
 - NeuroSTORM. 20 TR (4D Swin transformer). $T > 20$ 자극은 앞 20 TR 만 사용 (truncate), $T < 20$ 은 zero padding.
 - SwiFT. 20 TR (Swin transformer 4D, depths (2, 2, 18, 2), num_heads (6, 12, 24, 48)). NeuroSTORM 과 동일한 truncate / pad 정책.
- Per-stim embedding. 각 자극의 brain feature 를 한 벡터로 pooled. Brain-JEPA 는 ViT 의 global average pooled CLS feature (768-dim). NeuroSTORM 과 SwiFT 는 마지막 stage 의 spatial+temporal mean pooled feature (모델 크기에 따라 288 / 768 / 1536).
- Output. `output/embeddings/{model}_{init}_pad-{padding}/sub-XX.pt` 에 저장. payload 는 `embeddings (N, D), stim_num (N,), padding_ratio (N,), original_T (N,)`.

Variants 측정 대상 본 phase 1 에서 측정한 BFM variants

- Brain-JEPA (resting-pretrained, scratch). `embed_dim=768`.
- NeuroSTORM (resting-pretrained, scratch). `embed_dim=288`.
- SwiFT 변종 7 종.

- NewE36 (embed_dim=288), NewE96 (768), NewE192 (1536). 모두 ver11 RoPE 4D Swin, MR=0.8.
- UAH-5M (288), UAH-51M (768), UAH-202M (1536). 모두 ver9 4D Swin, MR=0.6.

- 각 SwiFT variant 에 resting + scratch init 두 가지.

Pretrained checkpoint loading caveat NeuroSTORM 과 SwiFT 의 pretrained checkpoint 는 우리 input shape 와 정확히 일치하므로 prefix strip 후 `strict=False` 로 그대로 load. Brain-JEPA 의 pretrained checkpoint 만 원본 input 의 시간 patch 수 (10 patch) 와 우리 input (1 patch) 이 달라서 두 가지 adaptation 적용.

- `pos_embed_proj.emb_h` 의 10 time patch 분량을 단순 평균하여 1 patch 로 collapse.
- `patch_embed.proj.weight` kernel 을 `F.interpolate(mode="linear")` 로 우리 size 에 맞춤.

따라서 본 결과의 “Brain-JEPA” 는 origin BJ paper 의 reference 가 아니라 “BJ adapted variant” 임을 명기.

2.4 Probing protocol

추출된 frozen embedding 위에서 두 가지 head 학습.

Input normalization 모든 head 학습 전 `StandardScaler` 로 train fold 의 mean / std 로 정규화한 후 train / val / test 동일 transform.

Linear probe (sklearn dispatch)

- Binary. `LogisticRegression` (L2 penalty, `class_weight=balanced`, `lbfgs`, `max_iter=5000`). HP grid $C \in \{10^{-3}, 10^{-2}, 10^{-1}, 1, 10, 100\}$.
- Regression. `Ridge`. HP grid α 동일 6 점.
- Multinomial. `LogisticRegression` 동일 setting.
- Multi-output regression. `MultiOutputRegressor(Ridge)`.
- Multi-label. per-category L2 logistic regression $\times 34$, `joblib` threading. HP grid $C \in \{10^{-2}, 1, 100\}$ (runtime 축소).
- Soft distribution. `MultiOutputRegressor(Ridge)` + 예측 후 합 1 로 normalize.

각 HP grid 안에서 train fold 로 학습 후 val fold 의 main metric 으로 최적 HP 선택, 그 모델로 test fold 평가.

MLP probe (SwiftMLP head)

- 구조. 2 개의 sequential block. 각 block 은 `MLPBlock` (`monai.Linear` ($d \rightarrow 4d$) $\rightarrow$ `GELU` $\rightarrow$ `Dropout(0.3)` $\rightarrow$ `Linear` ($4d \rightarrow d$) $\rightarrow$ `Dropout(0.3)`) 와 `LayerNorm` 의 sequential. 마지막에 `Linear` ($d \rightarrow \text{num_classes}$) head. weight 는 `trunc_normal_(std=0.02)` init.

- Hidden dim. `hidden_dim = in_dim`. 즉 input 차원이 클수록 head params 도 커진다 (288-dim $\rightarrow$ 0.83M params, 768-dim $\rightarrow$ 5.9M, 1536-dim $\rightarrow$ 23.7M).
- Optimizer. Adam, `weight_decay` 10^{-4} .
- Hyper-parameters (모든 BFM, video, ROI, 모든 task 공통).
 - `MLP_LRS` = $\{10^{-4}, 3 \times 10^{-4}, 10^{-3}, 3 \times 10^{-3}, 10^{-2}\}$
 - Batch size 8, max epoch 40, early stop patience 10 (val metric 기준).
 - Loss. CrossEntropy (binary / multinomial), BCEWithLogits (multilabel), KLDivLoss (soft distribution), MSE (regression).
 - Class imbalance 대응. binary / multinomial 에서 inverse frequency 로 sample weight (`class_weight` 대응).
- y normalization. regression / multi-output regression task 의 경우 학습 안정성을 위해 train fold 의 y 를 평균 / 표준편차로 normalize 후 학습, 예측 시 다시 원래 scale 로 복원. linear (Ridge) 은 closed-form 이라 불필요.
- Seed. `torch.manual_seed(0) + np.random.seed(0)`. 본 phase 1 은 1 seed 만 측정 (final paper 단계에 0, 1, 2 로 확장 예정).

Subject mode Pooled 와 per-subject 두 mode 가 모두 측정되었다. 본 문서의 결과표는 **pooled mode** 만 표시한다.

- Pooled. 5 subject 의 같은 split embedding 을 모두 합쳐서 한 head 로 학습 (train sample ≈ 1311 자극 $\times 5 = 6555$).
- Per-subject (supplementary). subject 별로 따로 학습. 5 subject 의 점수를 평균. train sample ≈ 1311 .

Phase 1 의 question 이 group-level brain representation 이라 pooled 가 main 으로 적합 (sample 크기 약 5 배, individual difference noise 가 평균으로 흡수). 두 mode 모두 stim-level split 공유로 leakage 없다.

2.5 Tasks

- `V_binary`. `v_quartile` $\in \{0, 3\}$ (= Q1 vs Q4) 자극 1131 개만 사용. label 0 = Q1 ($V \in 1.00\text{--}3.56$), label 1 = Q4 ($V \in 6.78\text{--}9.00$). Logistic L2. main metric AUROC.
- `A_binary`. `a_quartile` $\in \{0, 3\}$ 자극 1107 개. label 0 = Q1 ($A \in 2.00\text{--}5.11$), label 1 = Q4 ($A \in 6.44\text{--}8.67$). main metric AUROC.
- `V_reg`. 전체 2185 자극의 continuous valence score (1–9) regression. Ridge. main metric Pearson r.
- `A_reg`. 전체 2185 자극의 continuous arousal score (2–8.67) regression. Ridge. main metric Pearson r.

- **Cat34_multilabel.** 각 자극의 34 category score 가 threshold 0.10 (= 1/10 raters, 자연 단위) 이상이면 양성. 평균 자극당 4.93 category 가 양성, zero-label 자극 없음, minority category 도 약 15 자극 (3 / fold) 안정. 이전 threshold 0.15 는 임의 round number 였고 2026-06-07 sensitivity analysis 후 0.10 으로 결정. per-category L2 logistic $\times$ 34. main metric category-wise AUROC 의 macro 평균.
- **Cat34_soft.** 각 자극의 34 score 를 합 1 로 normalize 한 distribution 을 target. MultiOutputRegressor(Ridge) + 예측 후 normalize. main metric category-wise Pearson r 의 평균.

측정되지 않은 task 코드에는 다음 두 task 도 정의되어 있으나 본 phase 1 의 launch 에서는 결과 CSV 가 생성되지 않음.

- **Cat34_top1.** 34 score 의 argmax 를 정답 class 로 한 multinomial. 자극 분포가 극단적으로 imbalanced (4 category 는 top1 0 회 등장, 최저 class 는 2 자극만) 이라서 일부 fold 의 train 에 일부 class 가 부재 (“broken folds”). 코드 docstring 에 supplementary, broken folds 로 명시.
- **Dim14_multi.** 14 차원 affective rating 의 동시 regression. Phase 1 결과 디렉토리에 해당 CSV 가 없어서 본 문서에서는 제외.

2.6 Baselines

- Chance (절대 floor). feature 무관 `sklearn.dummy` predictor.
 - Binary / Multinomial. `DummyClassifier(strategy="stratified")` (train fold 의 class 비율 대로 random, seed 영향) 와 `strategy="most_frequent"` (다수 class 만 출력, deterministic).
 - Regression. `DummyRegressor(strategy="mean")` 과 `"median"`.
 - Multi-output regression. `"mean"`.

Stratified 는 seed $\in \{0, 1, 2\}$ 평균, deterministic 은 1 seed.

- Tier 1 ROI floor. Schaefer 17n400p (cortical 400) + Tian S3 50 (subcortical) = 450 ROI 의 BOLD time series 를 시간축 평균 $\rightarrow$ (450,) feature vector. 시간축 평균이라 T 가 5 든 47 이든 같은 차원으로 나와 padding 의 영향이 없다. 그 위에 위와 동일한 linear / MLP probe.
- Tier 3 video baseline. CLIP (1024-dim), DINOv2 (1536), VideoMAE (1280), V-JEPA2 (1408) 각각의 pretrained 와 random-init scratch, 그리고 Qwen-VL caption embedding (768-dim). 모두 자극당 1 벡터로 stim-level probe.

3 Results

표의 cell 은 `mean  $\pm$  std` 형식. 5 fold 의 sample standard deviation (1 seed). 모든 BFM 결과는 zero padding scope (사용자 결정). 단 NeuroSTORM 만 결과 benchmark CSV 에 zero padding row 가 없고 mean padding 결과만 surface 되어 있어 (NS 의 별도 split CSV 는 1E 단계에서 cross-check 예정) 본 표에서는 reported padding 을 그대로 사용. ROI 는 시간축 평균 (time_mean) 이라 padding 영향 없음.

Binary task 는 main metric 인 AUROC 와 함께 balanced accuracy (bAcc) 를 보조 metric 으로 표시. Regression task 는 Pearson r 외에 MAE (mean absolute error) 와 MSE (mean squared error) 를 함께 표시. Video feature (Tier 3) 의 결과는 본 표에서 생략 (별도 문서로 분리).

표 1: Task V_binary (Q1 vs Q4 binary). Pooled mode, 5-fold CV (1 seed). bAcc = balanced accuracy. Best value per column **among BFM rows** in bold (ROI baseline and chance excluded from comparison). Padding = zero for BFM, time_mean for ROI, mean for NeuroSTORM (as launched).

Model	Init	Linear		MLP	
		AUROC	bAcc	AUROC	bAcc
ROI (Schaefer400+Tian50)	–	0.789 ± 0.012	0.720 ± 0.011	0.763 ± 0.014	0.700 ± 0.024
Brain-JEPA	resting	0.738 ± 0.019	0.677 ± 0.018	0.708 ± 0.018	0.658 ± 0.016
	scratch	0.696 ± 0.018	0.648 ± 0.022	0.577 ± 0.039	0.559 ± 0.031
NeuroSTORM	resting	0.702 ± 0.019	0.645 ± 0.015	0.690 ± 0.027	0.642 ± 0.022
	scratch	0.641 ± 0.026	0.605 ± 0.022	0.619 ± 0.020	0.584 ± 0.015
SwiFT NewE36	resting	0.662 ± 0.027	0.618 ± 0.023	0.615 ± 0.024	0.586 ± 0.012
	scratch	0.599 ± 0.007	0.571 ± 0.013	0.587 ± 0.007	0.560 ± 0.012
SwiFT NewE96	resting	0.688 ± 0.017	0.640 ± 0.011	0.595 ± 0.019	0.559 ± 0.025
	scratch	0.631 ± 0.016	0.593 ± 0.016	0.607 ± 0.007	0.573 ± 0.011
SwiFT NewE192	resting	0.686 ± 0.022	0.634 ± 0.010	0.616 ± 0.004	0.588 ± 0.011
	scratch	0.625 ± 0.019	0.590 ± 0.022	0.605 ± 0.015	0.571 ± 0.011
SwiFT UAH-5M	resting	0.613 ± 0.025	0.588 ± 0.014	0.537 ± 0.011	0.516 ± 0.010
	scratch	0.626 ± 0.007	0.588 ± 0.008	0.602 ± 0.013	0.578 ± 0.012
SwiFT UAH-51M	resting	0.659 ± 0.016	0.620 ± 0.009	0.522 ± 0.019	0.501 ± 0.002
	scratch	0.633 ± 0.022	0.599 ± 0.027	0.611 ± 0.013	0.579 ± 0.009
SwiFT UAH-202M	resting	0.665 ± 0.006	0.623 ± 0.006	0.498 ± 0.050	0.502 ± 0.004
	scratch	0.663 ± 0.013	0.625 ± 0.012	0.653 ± 0.014	0.608 ± 0.022
Chance	stratified	0.505 ± 0.033	0.505 ± 0.033	–	–
Chance	most_frequent	0.500 ± 0.000	0.500 ± 0.000	–	–

Table 2: Task A_binary (Q1 vs Q4 binary). Pooled mode, 5-fold CV (1 seed). bAcc = balanced accuracy. Best value per column **among BFM rows** in bold (ROI baseline and chance excluded from comparison). Padding = zero for BFM, time_mean for ROI, mean for NeuroSTORM (as launched).

Model	Init	Linear		MLP	
		AUROC	bAcc	AUROC	bAcc
ROI (Schaefer400+Tian50)	–	0.678 ± 0.053	0.638 ± 0.038	0.660 ± 0.039	0.610 ± 0.033
Brain-JEPA	resting	0.662 ± 0.038	0.618 ± 0.029	0.649 ± 0.041	0.605 ± 0.033
	scratch	0.628 ± 0.026	0.600 ± 0.022	0.562 ± 0.016	0.542 ± 0.008
NeuroSTORM	resting	0.637 ± 0.052	0.597 ± 0.034	0.620 ± 0.032	0.585 ± 0.012
	scratch	0.581 ± 0.022	0.560 ± 0.019	0.567 ± 0.024	0.550 ± 0.018
SwiFT NewE36	resting	0.613 ± 0.037	0.586 ± 0.031	0.600 ± 0.031	0.579 ± 0.030
	scratch	0.585 ± 0.024	0.560 ± 0.019	0.576 ± 0.025	0.547 ± 0.031
SwiFT NewE96	resting	0.605 ± 0.032	0.577 ± 0.029	0.584 ± 0.025	0.560 ± 0.024
	scratch	0.564 ± 0.019	0.540 ± 0.016	0.570 ± 0.020	0.549 ± 0.011
SwiFT NewE192	resting	0.609 ± 0.033	0.587 ± 0.028	0.598 ± 0.029	0.534 ± 0.030
	scratch	0.599 ± 0.022	0.575 ± 0.021	0.580 ± 0.025	0.561 ± 0.020
SwiFT UAH-5M	resting	0.571 ± 0.032	0.557 ± 0.029	0.580 ± 0.019	0.567 ± 0.021
	scratch	0.598 ± 0.028	0.576 ± 0.026	0.578 ± 0.033	0.539 ± 0.019
SwiFT UAH-51M	resting	0.595 ± 0.032	0.564 ± 0.029	0.574 ± 0.021	0.513 ± 0.028
	scratch	0.594 ± 0.021	0.572 ± 0.018	0.583 ± 0.015	0.562 ± 0.013
SwiFT UAH-202M	resting	0.621 ± 0.033	0.588 ± 0.030	0.554 ± 0.023	0.535 ± 0.032
	scratch	0.604 ± 0.028	0.582 ± 0.028	0.582 ± 0.017	0.553 ± 0.021
Chance	stratified	0.480 ± 0.030	0.480 ± 0.030	–	–
Chance	most_frequent	0.500 ± 0.000	0.500 ± 0.000	–	–

Table 3: Task V_reg (continuous regression). Pooled mode, 5-fold CV (1 seed). Best value per column among BFM rows in bold (ROI baseline and chance excluded; MAE / MSE bold = minimum, Pearson r bold = maximum).

Model	Init	Linear			MLP		
		Pearson r	MAE	MSE	Pearson r	MAE	MSE
ROI (Schaefer400+Tian50)	–	0.396 ± 0.013	1.499 ± 0.017	3.292 ± 0.042	0.416 ± 0.022	1.487 ± 0.055	3.412 ± 0.182
Brain-JEPA	resting	0.330 ± 0.024	1.554 ± 0.026	3.461 ± 0.133	0.311 ± 0.019	1.564 ± 0.027	3.663 ± 0.227
	scratch	0.244 ± 0.025	1.607 ± 0.029	3.688 ± 0.122	0.093 ± 0.034	1.659 ± 0.020	3.896 ± 0.040
NeuroSTORM	resting	0.280 ± 0.023	1.581 ± 0.019	3.584 ± 0.095	0.297 ± 0.021	1.587 ± 0.026	3.809 ± 0.256
	scratch	0.183 ± 0.031	1.636 ± 0.024	3.795 ± 0.096	0.178 ± 0.027	1.654 ± 0.028	3.904 ± 0.131
SwiFT NewE36	resting	0.217 ± 0.027	1.619 ± 0.017	3.718 ± 0.119	0.153 ± 0.022	1.662 ± 0.013	3.977 ± 0.092
	scratch	0.141 ± 0.011	1.652 ± 0.013	3.847 ± 0.074	0.119 ± 0.007	1.651 ± 0.016	3.964 ± 0.057
SwiFT NewE96	resting	0.251 ± 0.020	1.601 ± 0.015	3.656 ± 0.098	0.135 ± 0.025	1.662 ± 0.043	3.994 ± 0.130
	scratch	0.184 ± 0.018	1.645 ± 0.019	3.919 ± 0.096	0.151 ± 0.018	1.671 ± 0.039	4.177 ± 0.296
SwiFT NewE192	resting	0.255 ± 0.035	1.600 ± 0.020	3.645 ± 0.130	0.142 ± 0.009	1.721 ± 0.046	4.338 ± 0.325
	scratch	0.145 ± 0.009	1.714 ± 0.018	4.356 ± 0.071	0.143 ± 0.006	1.724 ± 0.071	4.508 ± 0.364
SwiFT UAH-5M	resting	0.146 ± 0.038	1.660 ± 0.030	3.891 ± 0.196	0.027 ± 0.031	1.677 ± 0.013	3.892 ± 0.085
	scratch	0.169 ± 0.023	1.642 ± 0.012	3.818 ± 0.067	0.155 ± 0.021	1.707 ± 0.088	4.430 ± 0.605
SwiFT UAH-51M	resting	0.220 ± 0.025	1.626 ± 0.023	3.792 ± 0.171	0.020 ± 0.035	1.764 ± 0.185	4.268 ± 0.834
	scratch	0.191 ± 0.017	1.651 ± 0.011	3.925 ± 0.099	0.177 ± 0.013	1.655 ± 0.033	4.019 ± 0.256
SwiFT UAH-202M	resting	0.247 ± 0.017	1.611 ± 0.017	3.757 ± 0.166	-0.008 ± 0.054	1.663 ± 0.028	4.018 ± 0.198
	scratch	0.173 ± 0.013	1.703 ± 0.016	4.254 ± 0.096	0.194 ± 0.009	1.665 ± 0.054	4.056 ± 0.183
Chance	mean	0.000 ± 0.000	1.671 ± 0.012	3.860 ± 0.071	–	–	–
Chance	median	0.000 ± 0.000	1.639 ± 0.011	4.047 ± 0.086	–	–	–

Table 4: Task A_reg (continuous regression). Pooled mode, 5-fold CV (1 seed). Best value per column among BFM rows in bold (ROI baseline and chance excluded; MAE / MSE bold = minimum, Pearson r bold = maximum).

Model	Init	Linear			MLP		
		Pearson r	MAE	MSE	Pearson r	MAE	MSE
ROI (Schaefer400+Tian50)	–	0.233 ± 0.052	0.712 ± 0.009	0.806 ± 0.026	0.225 ± 0.050	0.733 ± 0.027	0.854 ± 0.072
Brain-JEPA	resting	0.221 ± 0.030	0.707 ± 0.011	0.796 ± 0.036	0.214 ± 0.039	0.721 ± 0.015	0.829 ± 0.049
	scratch	0.158 ± 0.027	0.720 ± 0.010	0.828 ± 0.035	0.096 ± 0.025	0.725 ± 0.008	0.831 ± 0.026
NeuroSTORM	resting	0.191 ± 0.060	0.713 ± 0.007	0.811 ± 0.025	0.157 ± 0.046	0.726 ± 0.018	0.831 ± 0.041
	scratch	0.113 ± 0.014	0.727 ± 0.010	0.841 ± 0.037	0.111 ± 0.022	0.730 ± 0.020	0.843 ± 0.062
SwiFT NewE36	resting	0.154 ± 0.038	0.718 ± 0.008	0.816 ± 0.028	0.156 ± 0.052	0.718 ± 0.007	0.819 ± 0.021
	scratch	0.108 ± 0.022	0.728 ± 0.012	0.840 ± 0.034	0.106 ± 0.018	0.725 ± 0.009	0.832 ± 0.036
SwiFT NewE96	resting	0.141 ± 0.029	0.717 ± 0.009	0.819 ± 0.033	0.120 ± 0.029	0.721 ± 0.009	0.826 ± 0.036
	scratch	0.090 ± 0.020	0.749 ± 0.015	0.889 ± 0.038	0.099 ± 0.020	0.759 ± 0.008	0.912 ± 0.044
SwiFT NewE192	resting	0.143 ± 0.030	0.723 ± 0.009	0.833 ± 0.031	0.137 ± 0.045	0.720 ± 0.014	0.824 ± 0.041
	scratch	0.092 ± 0.017	0.782 ± 0.013	0.967 ± 0.034	0.138 ± 0.017	0.746 ± 0.029	0.890 ± 0.081
SwiFT UAH-5M	resting	0.102 ± 0.028	0.724 ± 0.006	0.830 ± 0.027	0.122 ± 0.032	0.723 ± 0.011	0.827 ± 0.036
	scratch	0.100 ± 0.039	0.731 ± 0.008	0.848 ± 0.030	0.121 ± 0.033	0.723 ± 0.007	0.829 ± 0.036
SwiFT UAH-51M	resting	0.141 ± 0.031	0.719 ± 0.009	0.820 ± 0.030	0.101 ± 0.018	0.727 ± 0.011	0.840 ± 0.038
	scratch	0.096 ± 0.002	0.748 ± 0.012	0.887 ± 0.042	0.115 ± 0.018	0.728 ± 0.008	0.840 ± 0.028
SwiFT UAH-202M	resting	0.145 ± 0.035	0.721 ± 0.009	0.823 ± 0.029	0.094 ± 0.027	0.728 ± 0.012	0.837 ± 0.041
	scratch	0.096 ± 0.023	0.781 ± 0.015	0.962 ± 0.034	0.146 ± 0.032	0.782 ± 0.059	0.975 ± 0.122
Chance	mean	0.000 ± 0.000	0.725 ± 0.011	0.831 ± 0.039	–	–	–
Chance	median	0.000 ± 0.000	0.725 ± 0.012	0.836 ± 0.040	–	–	–

표 5: Task Cat34_multilabel (threshold 0.10 = 1/10 raters, natural unit) and Cat34_soft. Pooled mode, linear probe only (Cat34 launched with `-skip_mlp`). multilabel: macro AUROC over 34 categories + macro F1. soft: per-category Pearson r averaged over 34 categories + top1 accuracy (argmax of predicted distribution vs true argmax). mean $\pm$ std over 5 folds. Best value per column **among BFM rows** in bold (ROI baseline and chance excluded from comparison).

		Cat34_multilabel		Cat34_soft	
Model	Init / Head	macro AUROC	macro F1	Pearson r	top1 acc
Tier 1 baseline					
ROI (Schaefer400+Tian50)	linear	–	–	–	–
Tier 2 BFM (frozen)					
Brain-JEPA	resting	0.669 ± 0.006	0.298 ± 0.005	0.237 ± 0.005	0.309 ± 0.015
	scratch	0.638 ± 0.007	0.275 ± 0.005	0.198 ± 0.006	0.290 ± 0.015
NeuroSTORM	resting	0.658 ± 0.004	0.289 ± 0.004	0.214 ± 0.006	0.294 ± 0.022
	scratch	0.596 ± 0.009	0.250 ± 0.006	0.126 ± 0.006	0.250 ± 0.019
SwiFT NewE96	resting	0.624 ± 0.005	0.268 ± 0.003	0.171 ± 0.003	0.265 ± 0.020
	scratch	0.582 ± 0.005	0.239 ± 0.004	0.109 ± 0.005	0.234 ± 0.018
Chance					
Chance	stratified	–	–	–	–
Chance	most_frequent	–	–	–	–
Chance	shuffled	–	–	–	–
Chance	mean	–	–	–	–
Chance	uniform	–	–	–	–

4 ROI baseline 의 강한 성능에 대한 해석

표에서 확인되듯 단순한 **ROI mean BOLD + Ridge / Logistic regression** 의 점수가 사전학습된 BFM frozen embedding 보다 일관되게 높다. 이는 모델 구조 자체가 약한 것이 아니라 본 실험 setting 의 특수한 조건이 결합된 결과로 보인다.

- **Padding 의 confound.** 자극의 시간 길이 중앙값이 5 TR 이라서 BFM 의 input 중 평균 63–70% 가 zero. BFM 은 padding pattern 위에서 emotion-relevant 정보를 분리해야 한다. 반면 ROI 의 시간축 평균은 T 값에 무관하게 항상 동일한 (450,) 벡터를 산출하므로 padding artifact 의 영향이 없다.
- **BOLD amplitude 의 정보량.** emotion 관련 정보가 평균 BOLD amplitude 자체에 상당히 들어있다는 점은 fMRI decoding 문헌의 일반적 결론. 짧은 자극에서 추가로 추출 가능한 temporal dynamics 정보는 본질적으로 한계가 있다.
- **BFM 강점의 비활성화.** BFM 은 spatial $\times$ temporal joint dynamics 의 학습이 핵심 자원인데 우리 setting 에서는 활용할 temporal 정보 자체가 부족. 즉 BFM 의 architecture 자원이 본 실험에서 적절히 평가되지 못한다.

본 결과는 “frozen BFM 이 짧은 자극의 brain decoding 에는 부적합하다” 라는 phase 1 의 핵심

결론으로 정리되며, FEEL v4 framework 의 SSL 재학습 / LoRA fine-tune / subject-invariant 표상 학습 방향 전환의 직접 근거가 된다.

5 Notes (audit 단계에서 확인된 정합성 caveat)

본 문서의 결과 해석 시 참고해야 할 사항.

- Padding 비율. 자극의 T 분포가 매우 짧아 모델 입력의 평균 63% (BJ) – 70% (NS / SwiFT) 가 zero. 가장 흔한 $T = 5$ 자극의 경우 NS / SwiFT 입력의 75% 가 zero.
- Brain-JEPA 의 “adapted” 라벨. 위 §2.3 의 pretrained checkpoint adaptation 참조.
- Frame window 차이. BJ 는 $T \geq 16$ 자극을 중앙 16 TR, NS / SwiFT 는 앞 20 TR 만 사용. BFM 간 직접 비교는 같은 brain signal 위가 아니다.
- Single seed. MLP 결과는 seed 0 한 번. cross-seed variance 없음. paper 단계에서 seed 0, 1, 2 로 재추출 예정.
- Multilabel HP grid. linear multilabel 의 C grid 가 6 점이 아닌 3 점 (runtime). best C 가 grid 경계에 붙어 있을 가능성은 별도 확인 권고.
- NeuroSTORM padding. NS 의 main grid 가 zero 가 아닌 mean padding 으로 surface 된 점은 1E 단계 results consistency audit 에서 cross-check 예정.
- Cat34_multilabel 과 Cat34_soft 는 --skip_mlp 로 linear only (MLP 결과 없음).
- Cat34_top1, Dim14_multi 는 본 phase 1 result CSV 에서 발견되지 않음 (launch 누락 가능).
- **Cat34 의 ROI / chance baseline 보장 완료** (2026-06-06). Cat34_multilabel 과 Cat34_soft 의 ROI baseline 과 chance 가 누락되어 있었음. cat34_roi.sh (run_unified_probe.py ROI linear) 와 cat34_chance.sh (run_chance_cat34.py 신규) 로 보장. Cat34_soft 의 chance 는 train target distribution 을 test 자극에 random 재할당하는 shuffled dummy 로 측정 (mean / uniform dummy 는 prediction 의 per-cat std 가 0 이라서 Pearson r 정의 안 됨, top1 acc 만 정보).
- 기타 ML baseline (Random Forest, SVM, KNN, GBM) 은 미측정. Phase 1 의 핵심 비교 (frozen BFM vs simple statistical baseline) 의 정성적 결론은 ROI(Ridge/Logistic) + ROI(MLP) 까지로 이미 명확하므로 추가 baseline 의 marginal value 가 작음. Paper reviewer 요구 시 보장 가능.